Aprendizagem por Reforço

Fabrício Barth

Outubro de 2021

Contexto

Até o momento vimos nesta disciplina:

- Conceito de Agente Autônomo;
- Solução de problemas usando busca em espaço de estados:
  - ⋆ Algoritmos de busca cega, e;
  - ⋆ Algoritmos de busca informados.
- Busca competitiva.

Conteúdo desta aula

- Visão Geral sobre Aprendizagem por Reforço
- Algoritmo Q-Learning
- Implementações com o projeto GYM
- Considerações Finais
- Material de Consulta

Ao final desta aula você saberá

- o que é **Aprendizagem por Reforço** e como as suas principais ideias funcionam;
- como o algoritmo **Q-Learning** funciona e como implementá-lo;
- como implementar um **agente autônomo** usando aprendizagem por reforço, e;
- como implementar um agente autônomo para atuar nos ambientes do **projeto Gym**.

Taxi Driver

```
>>> import gym
>>> env = gym.make("Taxi-v3").env
>>> env.render()
+---------+
|R: | : :G|
| : | : : |
| : : : : |
| |: | : |
|Y| : |B: |
+---------+
```

Podemos implementar uma solução para este problema usando o algoritmo A^*. Neste caso, **o que é necessário fazer?**

Definir uma Heurística H que seja admissível e que traga algum valor para o processo de busca.

Ambientes competitivos

Podemos implementar uma solução para este tipo de problema usando o algoritmo MIN-MAX. Neste caso, **o que é necessário fazer?**

Definir uma função de utilidade que consegue descrever a utilidade dos estados possíveis para o meu agente.

E se fosse possível desenvolver um agente autônomo sem ter que codificar nenhum conhecimento sobre a tarefa que ele precisa executar (heurísticas ou funções de utilidade específicas)?

Aprendizagem por Reforço: Visão Geral

Um agente aprende a resolver uma tarefa através de repetidas interações com o ambiente, por tentativa e erro, recebendo (esporadicamente) reforços (punições ou recompensas) como retorno.

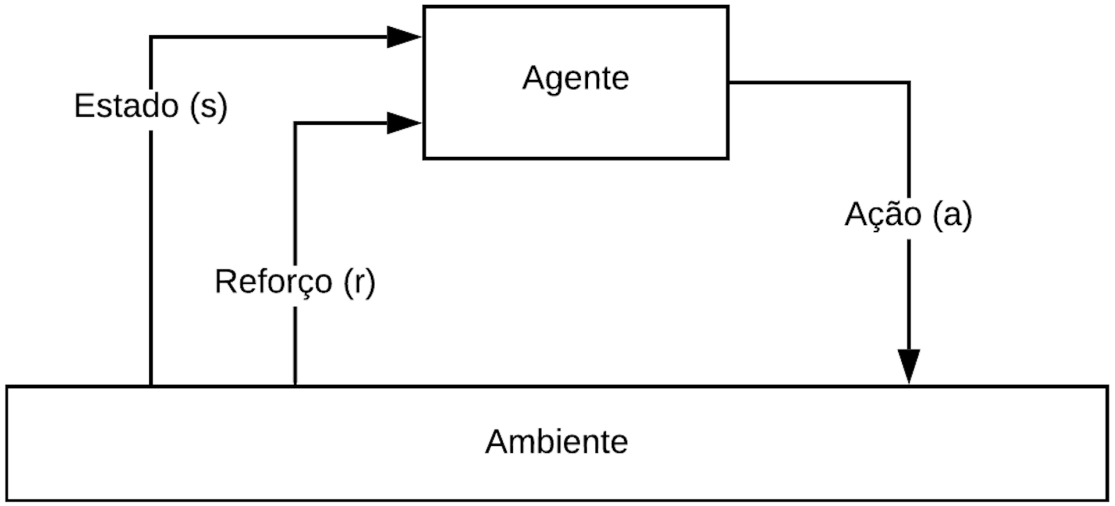

Aprendizagem por Reforço: Visão Geral

- Este agente não tem conhecimento algum sobre a tarefa que precisa executar (heurísticas ou funções de utilidade específicas).
- A **tarefa** deste agente é executar uma **sequência de ações**, observar as suas **consequências** e aprender uma **política de controle**.

O que é uma política de controle?

Política de Controle

- A política de controle desejada é aquela que **maximiza** os reforços (*reward*) acumulados ao longo do tempo pelo agente: $r_0 + \gamma r_1 + \gamma^2 r_2 + \cdots$ onde $0 \leq \gamma < 1$.

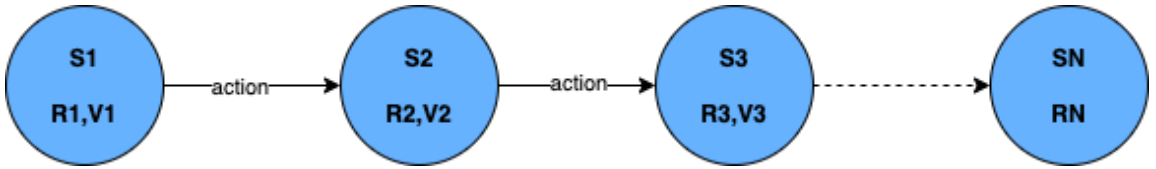

- O $V(s_1)$ será a soma de r_1 com o $V(s_2)$. No entanto, considerando o fator de desconto γ, temos: $V(s_1) = r_1 + \gamma V(s_2)$.
- O valor de um estado final leva-se em consideração apenas o reforço: $V(s_n) = r_n$.

Fator de desconto γ

- O fator de desconto (γ) é um hiperparâmetro que consiste em um número entre 0 e 1 que define a importância das recompensas futuras em relação a atual ($0 \leq \gamma < 1$).
- Valores mais próximos ao 0 dão mais importância a recompensas imediatas enquanto os mais próximos de 1 tentarão manter a importância de recompensas futuras.

Exemplo

Início	Campo	Campo	Campo
Campo	Buraco	Campo	Buraco
Campo	Campo	Campo	Buraco
Buraco	Campo	Campo	**Objetivo**

Ações:

- (0) Mover para Baixo; (1) Mover para Cima;
- (2) Move para Direita; (3) Move para Esquerda.

- Considerando que o local do objetivo, dos buracos e dos campos serão sempre os mesmos então temos **16** estados possíveis.
- Este problema tem **4** ações possíveis.
- Se o agente cair em um buraco ele recebe -1 como recompensa, se ele ir para um campo ele recebe 0 e ao chegar no objetivo ele recebe 1.
- Para que agente possa identificar uma política de controle ótima este agente precisa criar um **mapeamento** entre **estados** (S) e **ações** (A)

- Este mapeamento pode ser representado por uma função $Q(S, A)$ onde S são todos os estados possíveis $(s_1, s_2, \cdots)$ e onde A são todas as ações possíveis $(a_1, a_2, \cdots)$

Q-table	a_1	a_2	a_3	a_4
s_1				
s_2				
$\cdots$				
s_n				

- Para criar um **mapeamento** $Q(S, A)$ é necessário executar o agente no ambiente considerando o **reforço** dado por cada ação.

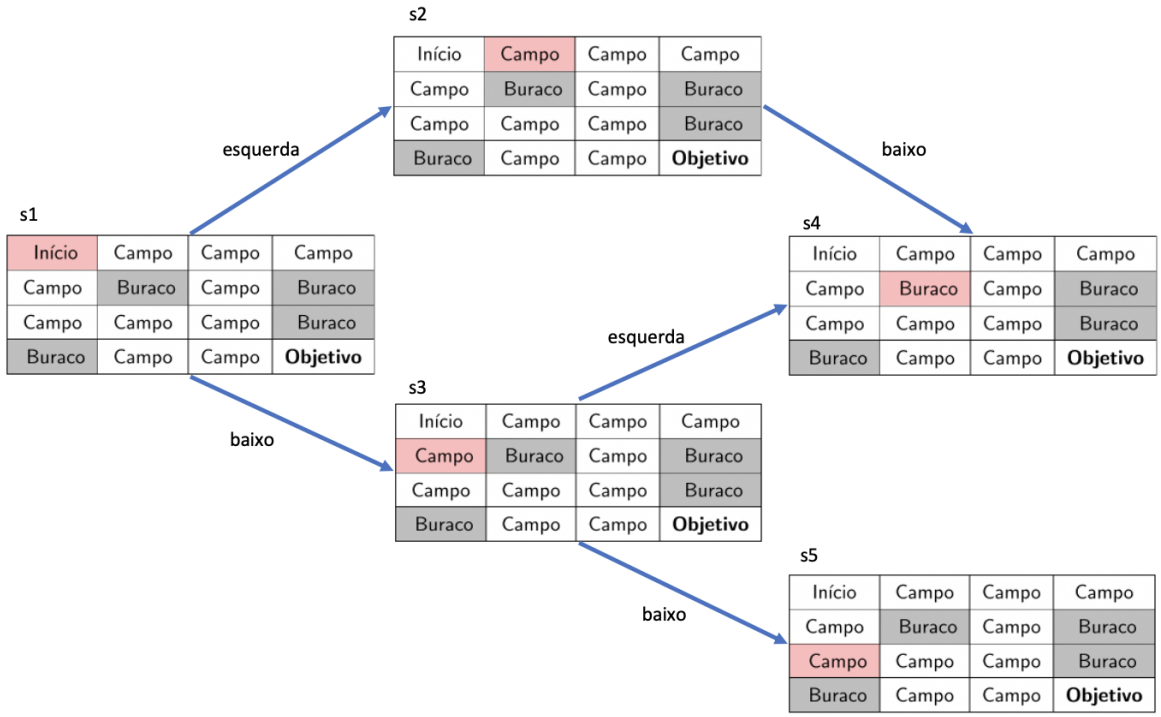

reforço

	esquerda	**baixo**
S1	0	0
S2	0	-1
S3	-1	0
S4	0	0
S5	0	0

- **Como é que o agente pode saber quais são as melhores ações em cada estado?**

Algoritmo Q-Learning

- A ideia é fazer com que o agente aprenda a função de mapeamento $Q(S, A)$. Ou seja, que seja capaz de identificar qual é a melhor ação para cada estado através das suas **experiências**.
- *Testando* **infinitas** vezes o ambiente. Ou seja, *testando* **muitas** vezes as combinações entre **estados** (S) e **ações** (A).

Início	Campo	Campo	Campo
Campo	Buraco	Campo	Buraco
Campo	Campo	Campo	Buraco
Buraco	Campo	Campo	**Objetivo**

Primeiro episódio ($\gamma = 0.9$):

$$
\begin{aligned}
Q(s_1, baixo) &\leftarrow r + \gamma \max_{a'} Q(s', a') \\
Q(s_1, baixo) &\leftarrow 0 + 0.9 \times \max[0, 0, 0] \\
Q(s_2, direita) &\leftarrow -1 + 0.9 \times \max[0, 0, 0, 0]
\end{aligned}
\tag{1}
$$

Q-table resultante da execução do 1^o episódio.

Q-table	$esquerda$	$baixo$	$direita$	$cima$
s_1	0	0	0	0
s_2	0	0	-1	0
s_3	0	0	0	0
s_4	0	0	0	0
...	...	...	...	...
s_n	0	0	1	0

Q-table resultante da execução do n-éssimo episódio.

Q-table	$esquerda$	$baixo$	$direita$	$cima$
s_1	0.02	0.03	0.0001	0.0001
s_2	0.00	0.05	-0.003	0.001
...	...	...	...	...
s_n	0.985	0.0001	0.003	0.002

Após a execução de n episódios o agente conhece qual a melhor ação para cada estado.

Algoritmo Q-Learning

function Q-Learning(env, α, γ, episódios)

inicializar os valores de $Q(s, a)$ arbitrariamente

for todos os episódios **do**

  inicializar s a partir de env

  repeat

    escolher uma ação a para um estado s

    executar a ação a

    observar a recompensa r e o novo estado s'

    $Q(s, a) \leftarrow Q(s, a) + \alpha[r + \gamma \max_{a'} Q(s', a') - Q(s, a)]$

    $s \leftarrow s'$

  until s ser um estado final

end for

return $Q(s, a)$

function Q-Learning(env, α, γ, episódios)
inicializar os valores de $Q(s, a)$ arbitrariamente
for todos os episódios **do**
  inicializar s a partir de env
  repeat
    escolher uma ação a para um estado s
    executar a ação a
    observar a recompensa r e o novo estado s'
    $Q(s, a) \leftarrow Q(s, a) + \alpha[r + \gamma \max_{a'} Q(s', a') - Q(s, a)]$
    $s \leftarrow s'$
  until s ser um estado final
end for
return $Q(s, a)$

function Q-Learning(env, α, γ, episódios)
inicializar os valores de $Q(s, a)$ arbitrariamente
for todos os episódios **do**
  inicializar s a partir de env
  repeat
    escolher uma ação a para um estado s
    executar a ação a
    observar a recompensa r e o novo estado s'
    $Q(s, a) \leftarrow Q(s, a) + \alpha[r + \gamma \max_{a'} Q(s', a') - Q(s, a)]$
    $s \leftarrow s'$
  until s ser um estado final
end for
return $Q(s, a)$

Algoritmo Q-Learning: hiperparâmetro α

- α é a taxa de aprendizado $(0 < \alpha \leq 1)$, quanto maior, mais valor dá ao novo aprendizado.

Que ação escolher?

function Q-Learning(env, α, γ, episódios)
inicializar os valores de $Q(s, a)$ arbitrariamente
for todos os episódios **do**
  inicializar s a partir de env
  repeat
    escolher uma ação a para um estado s
    executar a ação a
    observar a recompensa r e o novo estado s'
    $Q(s, a) \leftarrow Q(s, a) + \alpha[r + \gamma \max_{a'} Q(s', a') - Q(s, a)]$
    $s \leftarrow s'$
  until s ser um estado final
end for
return $Q(s, a)$

Exploration vs *Exploitation*

- A política que o agente utiliza para escolher uma ação a para um estado s não interfere no aprendizado da *Q-table*.
- No entanto, para que o algoritmo *Q-learning* possa convergir para um determinado problema é necessário que o algoritmo visite pares de ação-estado infinitas (muitas) vezes.
- Por isso, que a escolha de determinada *ação* em um *estado* poderia ser feita de forma **aleatória**.

- Porém, normalmente se utiliza uma política que inicialmente escolhe aleatoriamente as ações, e, à medida que vai aprendendo, passa a utilizar cada vez mais as decisões determinadas pela política derivada de Q.
- Esta estratégia inicia **explorando** (tentar uma ação mesmo que ela não tenha o maior valor de Q) e termina escolhendo a ação que tem o maior valor de Q (*exploitation*).

Exemplo de função para escolha de ações

A escolha de uma ação para um estado é dada pela função:

function escolha(s, ϵ): a
rv $=$ random $(0 < rv \leq 1)$
if $rv < \epsilon$ **then**
  return uma ação α aleatória em A
end if
return $\max_a Q(s, a)$

O fator de exploração ϵ $(0 \leq \epsilon \leq 1)$ inicia com um valor alto $(0.7$, por exemplo) e, conforme a simulação avança, diminiu: $\epsilon \leftarrow \epsilon \times \epsilon_{dec}$, onde $\epsilon_{dec} = 0.99$

Epsilon

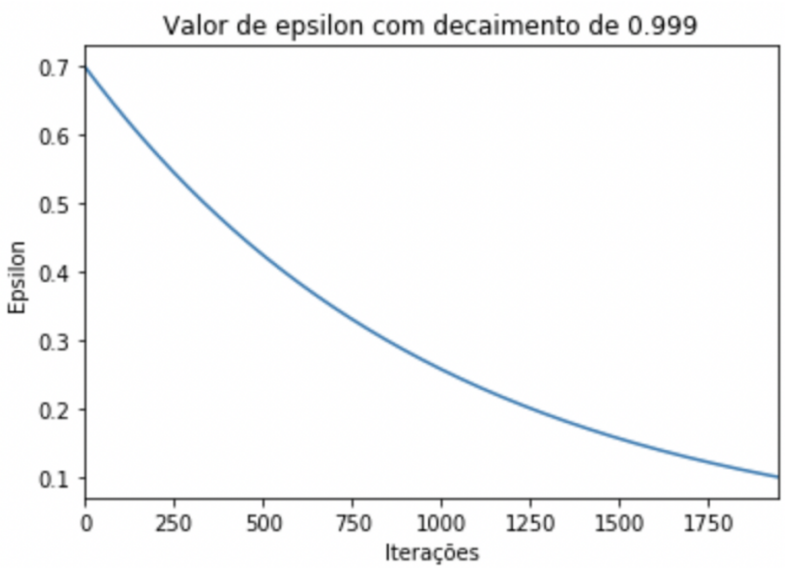
Valor de epsilon com decaimento de 0.999
Epsilon
0.7
0.6
0.5
0.4
0.3
0.2
0.1
0
250
500
750
1000
1250
1500
1750
Iterações

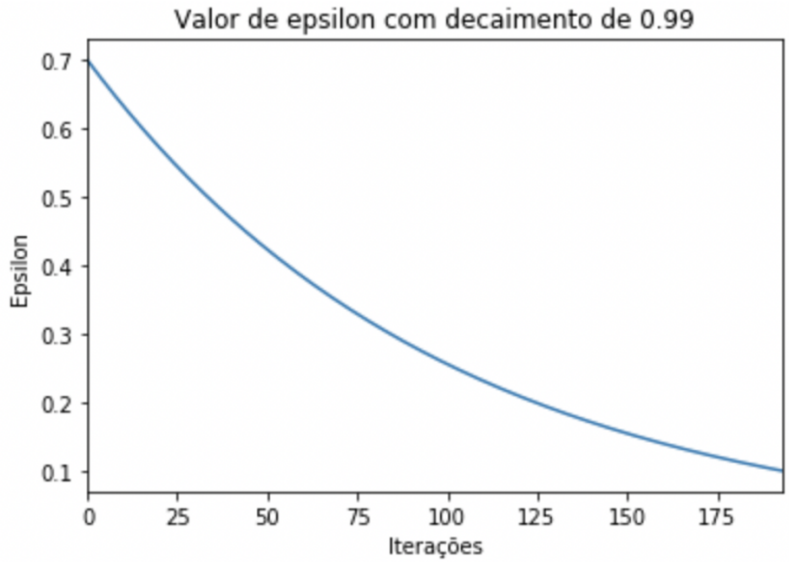
Valor de epsilon com decaimento de 0.99
Epsilon
0.7
0.6
0.5
0.4
0.3
0.2
0.1
0
25
50
75
100
125
150
175
Iterações

Algoritmo Q-Learning

function Q-Learning(env, α, γ, ϵ, ϵ_{min}, ϵ_{dec}, episódios)

inicializar os valores de $Q(s, a)$ arbitrariamente

for todos os episódios **do**

  inicializar s a partir de env

  repeat

    $a \leftarrow escolha(s, \epsilon)$

    $s', r \leftarrow$ executar a ação a no env

    $Q(s, a) \leftarrow Q(s, a) + \alpha[r + \gamma \max_{a'} Q(s', a') - Q(s, a)]$

    $s \leftarrow s'$

  until s ser um estado final

  if $\epsilon > \epsilon_{min}$ **then** $\epsilon \leftarrow \epsilon \times \epsilon_{dec}$

end for

return Q

Implementações com o projeto Gym

- Siga as orientações que estão no arquivo README.md da pasta https://github.com/fbarth/reinLearn.
- Execute as atividades que estão descritas no arquivo atividades_01.md no mesmo diretório (https://github.com/fbarth/reinLearn/atividades_01.md).

Considerações Finais

- O algoritmo *Q Learning* pode ser utilizado por agentes que não tem conhecimento prévio sobre o problema.
- Diversos autores já provaram que o algoritmo *Q Learning* converge para a função correta Q dentro de certas condições. Por exemplo, uma delas é garantir que o agente avalie um par $Q(s, a)$ diversas vezes.

- *Q Learning* converge tanto para processos de decisão de Markov (MDP) **determinísticos** e **não-determinísticos**.
- Na prática, o algoritmo *Q Learning* necessita de muitas iterações de treinamento até convergir, inclusive para problemas que não tem um espaço de busca tão grande.

- **E quando o espaço de busca for muito grande?**

- Usar *Deep Learning* com *Reinforcement Learning*!
  Assunto do nosso próximo encontro!
- Ler o capítulo *18. Reinforcement Learning* até a seção *Implementing Deep Q-Learning* do livro **Hands-On Machine Learning with Scikit-Learn, Keras, and TensorFlow, 2nd Edition** do Aurélien Géron.
- Referência adicional:
  https://deepmind.com/research/case-studies/alphago-the-story-so-far

O que vimos até o momento?

- Conceitos básicos de Aprendizagem por Reforço.
- Funcionamento do algoritmo Q-Learning.
- Funcionamento da biblioteca Gym.

Material de **consulta**

- Tom Mitchell. Machine Learning. McGraw-Hill, 1997.
- Richard Sutton and Andrew Barto. Reinforcement Learning: An Introduction. Second Edition, in progress. The MIT Press, 2015.
- Projeto Gym: https://gym.openai.com/
- https://deepmind.com/research/case-studies/alphago-the-story-so-far
- Aurélien Géron. Hands-On Machine Learning with Scikit-Learn, Keras, and TensorFlow, 2nd Edition, 2019.